چالش آماری علم داده، ترم ۳ (شماره ۱)

فایل داده: bank_midterm (۴۰۰ مشتری کارت بانکی).
هر کد، نمودار، خروجی و توضیح را در یک گزارش تحویل دهید. هر انتخاب آماری باید توجیه شود. بدون توجیه نمره‌ی کامل داده نمی‌شود. بخش‌های «مفهومی» را با استدلال ریاضی/آماری پاسخ دهید و نیازی به کد ندارند (پاسخ به صورت دستی نگارش شود). ماتریس هت در سوال ۱ باید با ماتریس‌ها ساخته شود.

توضیح متغیرها

- `income`، `savings`، `investments`، `total_assets`، `monthly_spend`: به میلیون تومان.
- `tenure_months`: مدت مشتری بودن (ماه).
- `n_products`: تعداد محصولات.
- `region`: تهران / مترو / سایر.
- `debt_ratio`: نسبت اقساط به درآمد.
- `late_payments`: تعداد تأخیر در ۱۲ ماه.
- `legal_case`: پرونده‌ی حقوقی باز (۰/۱).
- `monthly_spend`: پاسخ رگرسیون خطی.
- `default`: نکول (۰/۱)، پاسخ رگرسیون لجستیک.

سوال ۱ (۲۵ نمره): ساختار مدل، همخطی و نقاط تأثیرگذار

مدل

$$\text{monthly_spend} \sim \text{age} + \text{income} + \text{tenure_months} + \text{n_products} + \text{savings} + \text{investments} + \text{total_assets} + \text{region}$$

را روی داده‌ی خام برازش دهید.

الف) (۵ نمره): چه اتفاقی برای ضرایب می‌افتد؟ با رتبه‌ی ماتریس طرح و مقادیر ویژه‌ی $X'X$ علت را نشان دهید. مدل را اصلاح کنید و df باقی‌مانده را قبل و بعد از اصلاح توضیح دهید.

ب) (۶ نمره): VIF و number condition را حساب کنید. کدام متغیرها مشکل دارند و چرا؟ یک راه‌حل بدهید، مدل را دوباره برازش دهید و SE ضریب income را قبل و بعد مقایسه کنید. بگویید همخطی چه کمیت‌هایی را خراب می‌کند و چه کمیت‌هایی را نه.

ج) (۷ نمره) ماتریس هت را مستقیم با ماتریس‌ها بسازید (نه با تابع آماده).

تأیید کنید $\text{tr}(H) = p$

مشاهدات با $h_{ii} > \frac{2p}{n}$ را مشخص کنید.

سپس Cook's D، DFFITS و باقی‌مانده‌ی استیودنتی حذفی را حساب کنید و مشاهدات مهم را در سه دسته «اهرمی»، «پرت» و «تأثیرگذار» طبقه‌بندی کنید. «تأثیرگذار» یعنی هم اهرم و هم Cook بزرگ. مدل را بدون مشاهدات تأثیرگذار برازش دهید و تغییر ضرایب را گزارش کنید.

د) مفهومی (۷ نمره)

i- نشان دهید:

$$h_{ii} = \frac{\partial \hat{y}_i}{\partial y_i} \quad where\ 0 \leq h_{ii} \leq 1$$

ii- ثابت کنید باقی‌مانده‌ی PRESS (باقی‌مانده‌ی پیش‌بینی مشاهده‌ی i وقتی از برازش حذف شود) برابر مقدار زیر است:

$$y_i - \hat{y}_{(-i)} = \frac{e_i}{1 - h_{ii}}$$

iii- با استفاده از فرمول Cook توضیح دهید چرا یک مشاهده‌ی با اهرم بالا ممکن است D_i کوچک داشته باشد، و یک مشاهده‌ی پرت با اهرم کم ممکن است D_i متوسط داشته باشد. برای هر حالت با داده مثال بزنید:

$$D_i = \frac{e_i^2}{p.MSE^2} \cdot \frac{h_{ii}}{(1 - h_{ii})^2}$$

iv- این ادعا را نقد کنید: «مشاهده‌ی اهرم‌بالا باید حذف شود».

سوال ۲ (۲۵ نمره): فرضیات، تبدیل، WLS و رگرسیون مقاوم

از مدل اصلاح‌شده‌ی سوال ۱ (بدون total_assets و savings) روی همه‌ی داده استفاده کنید.

الف) (۶ نمره): نمودار باقی‌مانده‌ها در برابر مقادیر برازش‌شده، نمودار Q-Q را رسم و آزمون‌های Breusch–Pagan و Shapiro–Wilk را اجرا کنید. کدام فرض‌ها نقض شده‌اند؟ ساختار ناهمسانی واریانس را بر اساس نمودار و آزمون توصیف کنید.

ب) (۶ نمره): به امور زیر رسیدگی شود:

- تبدیل Box–Cox را روی monthly_spend اعمال کنید.
- نمودار لگاریتم درست‌نمایی را رسم کنید و λ بهینه را همراه با فاصله‌ی اطمینان ۹۵٪ گزارش کنید.
- بر اساس فاصله‌ی اطمینان، تبدیل مناسب را انتخاب کنید.
- مدل را با پاسخ تبدیل‌شده دوباره برازش کنید.
- تحلیل تشخیصی (نمودار باقی‌مانده‌ها در برابر برازش، Q-Q، Breusch–Pagan، Shapiro–Wilk) را تکرار کنید و با حالت قبل مقایسه کنید.
- تفسیر ضریب income را در مقیاس جدید بنویسید.

ج) (۶ نمره): به امور زیر رسیدگی شود:

- WLS را با وزن‌های برآوردشده از تابع واریانس برازش کنید و تابع واریانس انتخابی را توجیه کنید.
- برآوردگرهای OLS، WLS، OLS با خطای استاندارد مقاوم (HC3)، برآوردگر مقاوم Huber و برآوردگر مقاوم Tukey را روی مقیاس اصلی متغیر پاسخ مقایسه کنید.
- وزن‌های نهایی برآوردگر Tukey برای چه نوع مشاهداتی نزدیک صفر است؟ توضیح دهید.
- برای یک مشتری جدید با ویژگی‌های سن ۴۰، درآمد ۳۵، ۶۰ ماه، ۳ محصول، سرمایه‌گذاری ۴۰ و منطقه‌ی تهران، فاصله‌ی اطمینان ۹۵٪ برای میانگین پاسخ و فاصله‌ی پیش‌بینی ۹۵٪ برای یک مشاهده‌ی جدید را در مدل لگاریتمی محاسبه کنید و نتیجه را با تبدیل معکوس به مقیاس اصلی برگردانید.

د) مفهومی (۷ نمره)

i- تحت ناهمسانی واریانس، آیا برآوردگر OLS ناریب و سازگار است؟

ii- برآوردگر ساندویچی ماتریس کوواریانس برآوردگر OLS را استخراج کنید:

$$Var(\hat{\beta}_{OLS}) = (X'X)^{-1}X'\Sigma X(X'X)^{-1}$$

سپس نشان دهید که برآوردگر WLS: $\hat{\beta}_{WLS} = (X'WX)^{-1}X'Wy$

تحت چه شرطی روی W، بهترین برآوردگر خطی ناریب (BLUE) است.

iii- در مدل لگاریتمی $logy = X\beta + \varepsilon$

- نشان دهید $\exp(X\hat{\beta})$ برآوردگر میانه است، نه میانگین.
- اریبی پیش‌بینی روی مقیاس اصلی را با تصحیح نرمال $\exp(\hat{\sigma}^2/2)$ محاسبه کنید.
- اریبی پیش‌بینی را با تصحیح Duan (smearing) محاسبه کنید.
- دو تصحیح را روی مقیاس اصلی y مقایسه کنید و شرایط اعتبار هر کدام را توضیح دهید.