چالش آماری علم داده، ترم ۳ (شماره ۲)

فایل داده: csv.bank_midterm (۴۰۰ مشتری کارت بانکی).
هر کد، نمودار، خروجی و توضیح را در یک گزارش تحویل دهید. هر انتخاب آماری باید توجیه شود. بدون توجیه نمره‌ی کامل داده نمی‌شود. بخش‌های «مفهومی» را با استدلال ریاضی/آماری پاسخ دهید و نیازی به کد ندارند (پاسخ به صورت دستی نگارش شود). استفاده از هر نرم‌افزاری (R یا Python) آزاد است. ماتریس هت در سوال ۱ باید با ماتریس‌ها ساخته شود.

متغیرها

متغیر	توضیح
id	شماره‌ی مشتری
age	سن (سال)
income	درآمد ماهانه (میلیون تومان)
tenure_months	مدت مشتری بودن (ماه)
n_products	تعداد محصولات بانکی
savings	موجودی پس‌انداز (میلیون تومان)
investments	سرمایه‌گذاری (میلیون تومان)
total_assets	دارایی کل (میلیون تومان)
region	منطقه: Other / Metro / Tehran
debt_ratio	نسبت اقساط به درآمد
late_payments	تعداد تأخیر پرداخت در ۱۲ ماه گذشته
legal_case	پرونده‌ی حقوقی باز (۰ یا ۱)
monthly_spend	هزینه‌ی ماهانه‌ی کارت (میلیون تومان)، پاسخ رگرسیون خطی
default	نکول (۰ یا ۱)، پاسخ رگرسیون لجستیک

سوال ۱ (۲۰ نمره): اثر متقابل، چندجمله‌ای و اسپلاین

روی لگاریتم monthly_spend کار کنید و ۳ مشاهده‌ی تأثیرگذار سوال ۱ (در کوئیز اول) را حذف کنید.

الف) (۵ نمره): اثر متقابل درآمد و منطقه را با آزمون F بسنجید و شیب income را برای هر منطقه با فاصلهٔ اطمینان گزارش دهید و سپس، تفسیر درصدی کنید.

ب) (۷ نمره): اثر age را با نمودار باقی‌ماندهٔ جزئی نشان دهید. چندجمله‌ای درجه ۱ تا ۵ را با آزمون F تو در تو و اعتبارسنجی متقابل ده‌بخشی (با seed ثابت) مقایسه کنید. چندجمله‌ای خام و متعامد را از نظر VIF مقایسه کنید. سپس اسپلاین طبیعی و spline-B را با df انتخاب‌شده از اعتبارسنجی متقابل، برازش دهید. سن اوج هزینه را با بوت‌استرپ (۱۰۰۰ تکرار) و فاصله‌ی اطمینان گزارش کنید. آیا tenure_months هم غیرخطی است؟ (مدل جمعی ساده با اسپلاین و آزمون F).

ج) مفهومی (۸ نمره):

i. ثابت کنید تعداد پارامترهای اسپلاین مکعبی با K گره داخلی و اسپلاین طبیعی (با عرض از مبدأ) به ترتیب برابر مقادیر زیر است:

$$df_{cubic} = K + 4, \quad df_{natural} = K$$

ii. چرا چندجمله‌ای درجه بالا در مرزها، واریانس زیادی دارد (پدیده‌ی Runge) و قید خطی بودن در مرز چه کمکی می‌کند؟

iii. ماتریس هموارساز را به شکل زیر تعریف می‌کنیم:

$$\hat{y} = S\,y$$
$$S = B(B^T B)^{-1} B^T$$

توضیح دهید چرا رد این ماتریس درجه‌ی آزادی مؤثر است:

$$df_{eff} = tr(S)$$

همچنین توضیح دهید چرا مدل اسپلاین با df ثابت یک مدل خطی است ولی انتخاب df از روی داده این خاصیت را می‌شکند.

سوال ۲ (۳۰ نمره): رگرسیون لجستیک

برای مدل‌سازی جدید، پاسخ default خواهد بود.

الف) (۷ نمره): مدل لجستیک با متغیرهای مستقل
debt_ratio، late_payments، income، age، tenure_months، region و legal_case را برازش دهید.
چه مشکلی رخ می‌دهد؟ جدول متقاطع، رفتار IRLS (لگاریتم درستنمایی و ضریب egal_casel در تکرارها) و اندازهٔ خطای معیار را بررسی کنید. چرا آزمون Wald قابل‌اعتماد نیست و آزمون نسبت درستنمایی چه می‌گوید؟

ب) (۶ نمره): مشکل را به دو روش حل کنید: (۱) حذف متغیر با استدلال تحلیلی، (۲) Firth یا رگولاریزاسیون L۲ با انتخاب λ به کمک اعتبارسنجی متقابل. نتایج را مقایسه کنید. آیا legal_case از نظر زمانی و کسب‌وکاری باید در مدل باشد؟

ج) (۷ نمره): در مدل بدون legal_case: نسبت بخت (OR) با فاصله‌ی اطمینان ۹۵٪ برای افزایش ۰٫۱ در debt_ratio و یک تأخیر اضافه را گزارش کنید. اثر متقابل debt_ratio و منطقه را با آزمون نسبت درستنمایی بسنجید و OR جدا برای هر منطقه بدهید. McFadden R^2، deviance و AUC را حساب کنید. جدول طبقه‌بندی در آستانه‌ی ۰٫۵ را بسازید و آن را نقد کنید.

د) مفهومی (۱۰ نمره):

i. ثابت کنید گام نیوتن–رافسون برای بیشینه‌سازی درستنمایی لجستیک، همان IRLS است، با ماتریس وزن و پاسخ کاری زیر:

$$W = diag\left(\hat{p}_i(1 - \hat{p}_i)\right)$$
$$z = \eta + W^{-1}(y - \hat{p})$$

ii. تحت جدایی، چرا β به بی‌نهایت می‌رود، وزن‌ها به صفر میل می‌کنند و لگاریتم درستنمایی به صفر نزدیک می‌شود ولی هیچ‌وقت به آن نمی‌رسد؟ چرا Firth (جمله‌ی Jeffreys) این مشکل را برطرف می‌کند؟

iii. تابع softmax برای K کلاس به شکل زیر است. نشان دهید برای K =۲، با لجستیک معادل است و ارتباط آن با شبکه‌ی عصبی تک‌لایه با entropy-cross را توضیح دهید:

$$P(y = k) = \frac{exp(\eta_k)}{\sum_{j=1}^{K} exp(\eta_j)}$$

iv. نرخ نکول حدود ۲۰٪ است. چرا تفسیر OR به‌عنوان «۲ برابر شدن ریسک» غلط است؟ OR و RR (ریسک نسبی) به شکل زیر تعریف می‌شوند. رابطه‌ی بین آن‌ها را بنویسید و یک مثال عددی بزنید:

$$OR = \frac{\frac{p_1}{1 - p_1}}{\frac{p_0}{1 - p_0}}, \quad RR = \frac{p_1}{p_0}$$